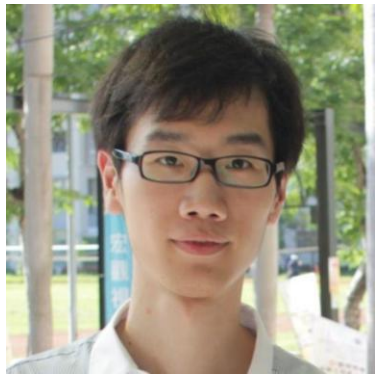
為甚麼SSIM不能上升

ReDi-7T : Unpaired 3T→7T Brain MRI Synthesis via Latent Regression and High-Frequency Residual Diffusion

OpenACC
More Science, Less Programming

Mentor



Yang-Hsien Lin
NVAITC



Ken Liao
NVIDIA

Advisor



Prof. Yi-Ping Chao
CGU

Team Member



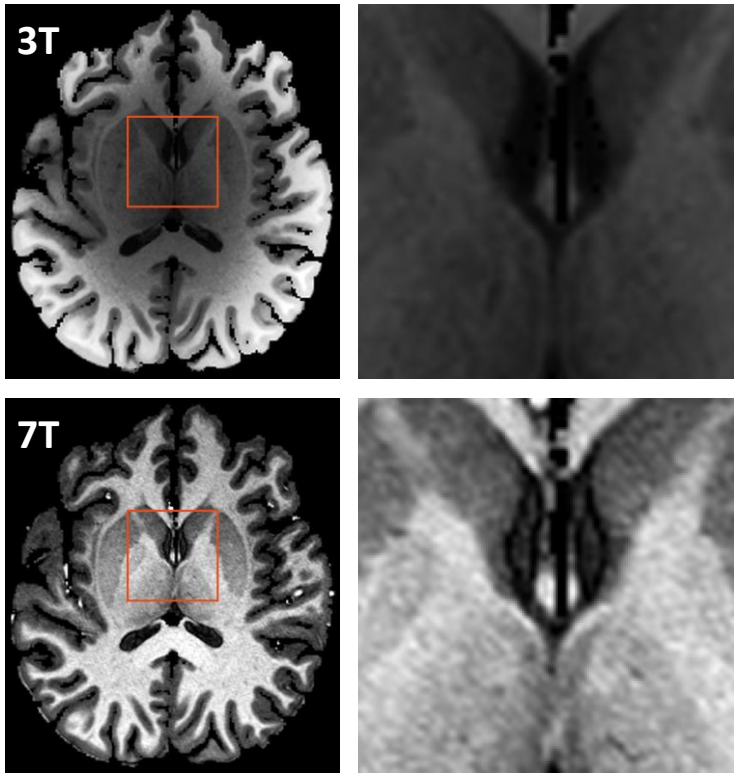
Ting-Yu Lee
CGU



Yu-Ru Wu
CGU

OpenACC More Science, Less Programming
OPEN HACKATHONS
NCHC 國家實驗研究院 國家高速網路與計算中心 National Center for High-performance Computing
NVIDIA

Why We Need 7T MRI image



同一位受試者（Chen sub-01），已對位；右為橘框放大

- **High resolution**
- **High SNR**
- **High Tissue contrast**

疾病	7T 對 3T
多發性硬化：皮質病灶	**偵測數量 > 2 倍**
抗藥性癲癇	**3T 陰性者 31% 在 7T 找到病灶**

Balchandani & Naidich, AJNR 2015；Kilsdonk et al., Brain 2016；van Lanen et al., NeuroImage Clin 2021

But 7T MRI Is Rare

142台

全球的超高場MRI磁振造影

0台

全台的人體7T磁振造影

3T

臨床上最普遍的高場 MRI

目標：用一般的 3T T1 影像，合成出 7T 等級的 T1 影像

Ultra-High Field MRI scanners



OpenACC More Science, Less Programming
OPEN HACKATHONS
NCHC 國家實驗研究院 國家高速網路與計算中心 National Center for High-performance Computing
NVIDIA

為什麼現有方法做不到



缺乏配對資料

- Paired data稀少
- 訓練用的 3T（HCP）和 7T（CEREBRUM、AHEAD）是不同的人逐像素的監督式訓練無法直接用



GAN 會產生幻覺

- 只要求輸出「分佈像 7T」
- 結構幻覺
- 醫學影像上，假結構可能被當成病灶



擴散模型太慢又全部重畫

- 實驗室既有 3D 擴散模型：**推論 90 分鐘 / 人**、訓練 **700 GPU-h** (RTX 3090)
- 所有頻率都生成，連 3T 已經有的結構和對比也可能畫錯

Cohen et al., MICCAI 2018；MC-IDDPM 數字由實驗室提供

Solution：頻段拆解

低頻 > 8 voxel

對比/強度不均

中頻 4–8 voxel

對比/部分細節

高頻 2–4 voxel

細節/雜訊

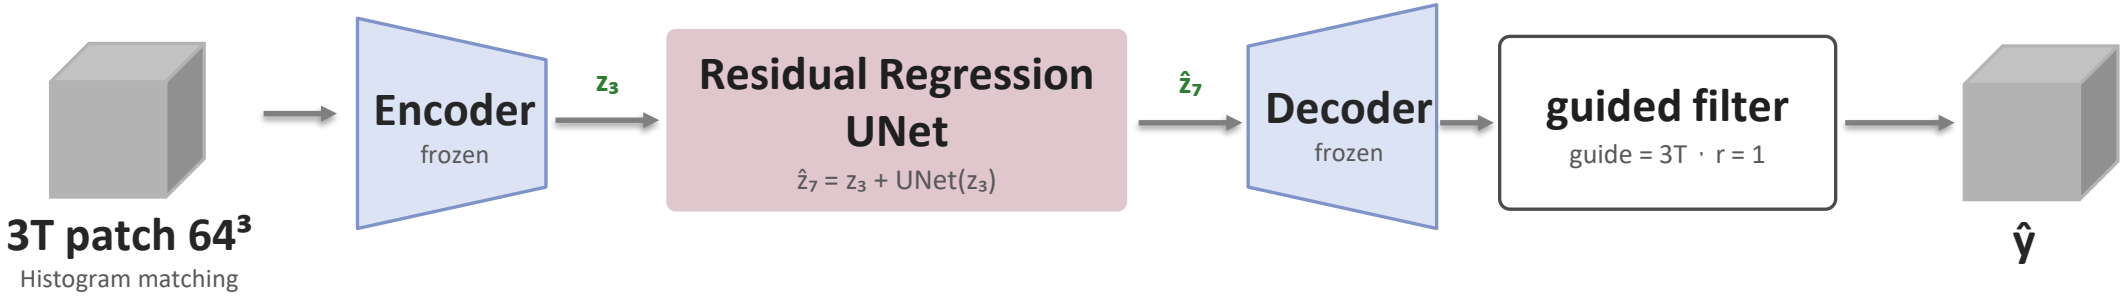
2-level wavelet decomposition: level-1 detail = high, level-2 detail = mid, approximation = low

空間頻率 → (0 到 0.5 cycles/voxel)

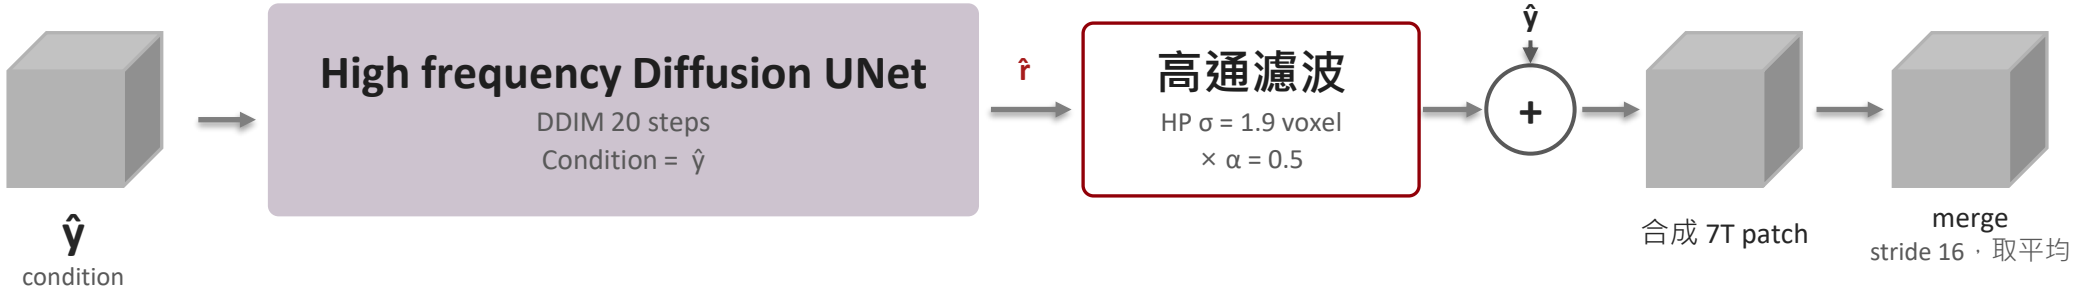
子問題	模組	為什麼這樣做
沒有成對資料	**退化模型 Φ**	產生pseudo-paired
低、中頻：對比、強度不均、可恢復的細節	**latent 殘差回歸 + guided filter**	確定性、快、不會亂畫結構
高頻	**影像空間高頻殘差擴散**	補上7T統計的紋理

3D pipeline：ReDi-7T

Stage 1 · Deterministic Restoration



Stage2 · High-Frequency Generation



Training data：退化模型 Φ（7T → 假 3T）
強度對應 3T、局部對比、bias 場、模糊、雜訊
7T（CEREBRUM-7T、AHEAD）→ 同一人配對

Regression loss（Stage 1）
latent MSE + L1 + (1 − SSIM)
SSIM 在影像空間：$D(\hat{z}_7)$ vs $D(z_7)$

High-Frequency Generation Goal（Stage 2）
$r = HP_{1.9}(7T - \hat{y})$：只學高頻殘差
Φ 假配對，40 epoch，EMA 0.999

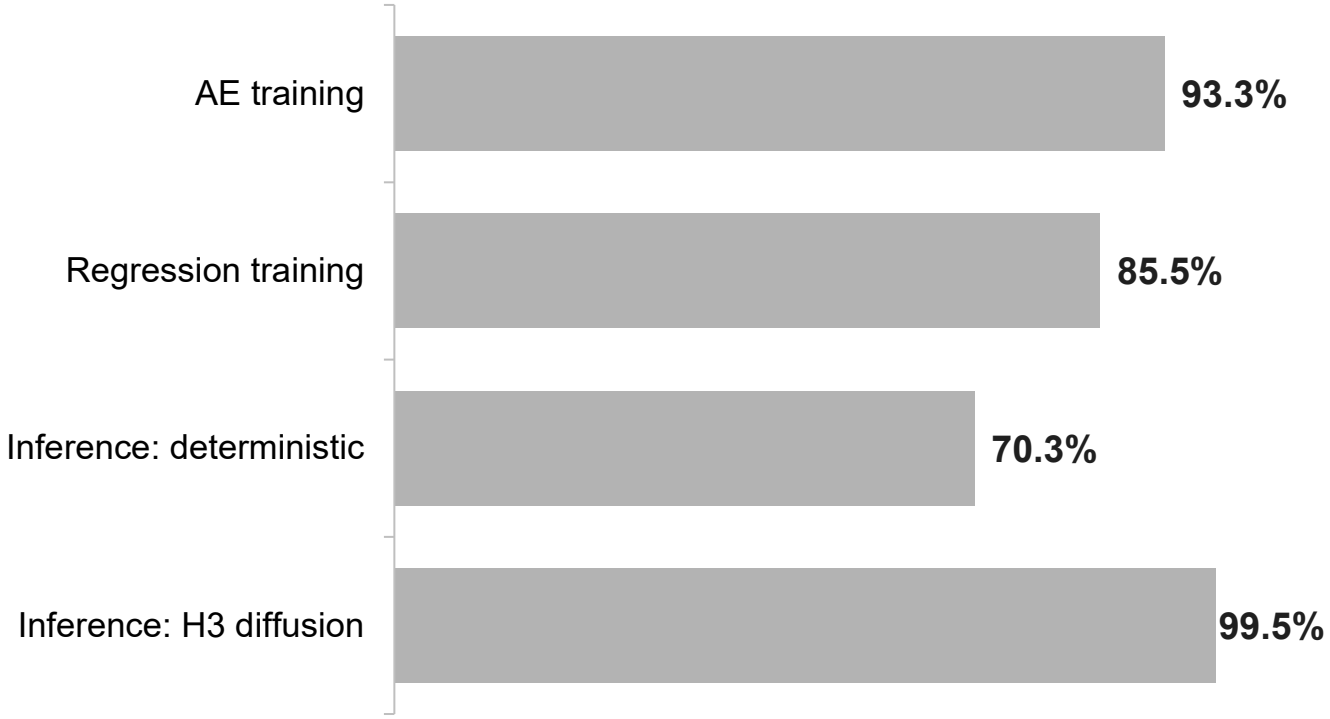
Inference: 64³ sliding window, stride 16, mean merge; AE (Encoder/Decoder) shared by 3T and 7T, frozen after training

OpenACC More Science, Less Programming
OPEN HACKATHONS
NCHC 國家實驗研究院 國家高速網路與計算中心 National Center for High-performance Computing
NVIDIA

Speedup Strategy

模型設計	Image space → **latent space + image space** Diffusion model → **Regression model + Diffusion model** 全頻生成　　只生成高頻（DDIM）
硬體	NVIDIA RTX 3090（24 GB）→ **H200（141GB）× 1**
軟體	Histogram matching CPU → **GPU** **unused branch removed (inference)** Batch 16 → **64 (regression training)** Repeated encoding → **cached latents (training)**

Where the GPU Time Goes (Before Optimization)



Mostly busy (85–99.5%)

Little idle time to recover

→ fuse small kernels (torch.compile)

→ do less work per sample

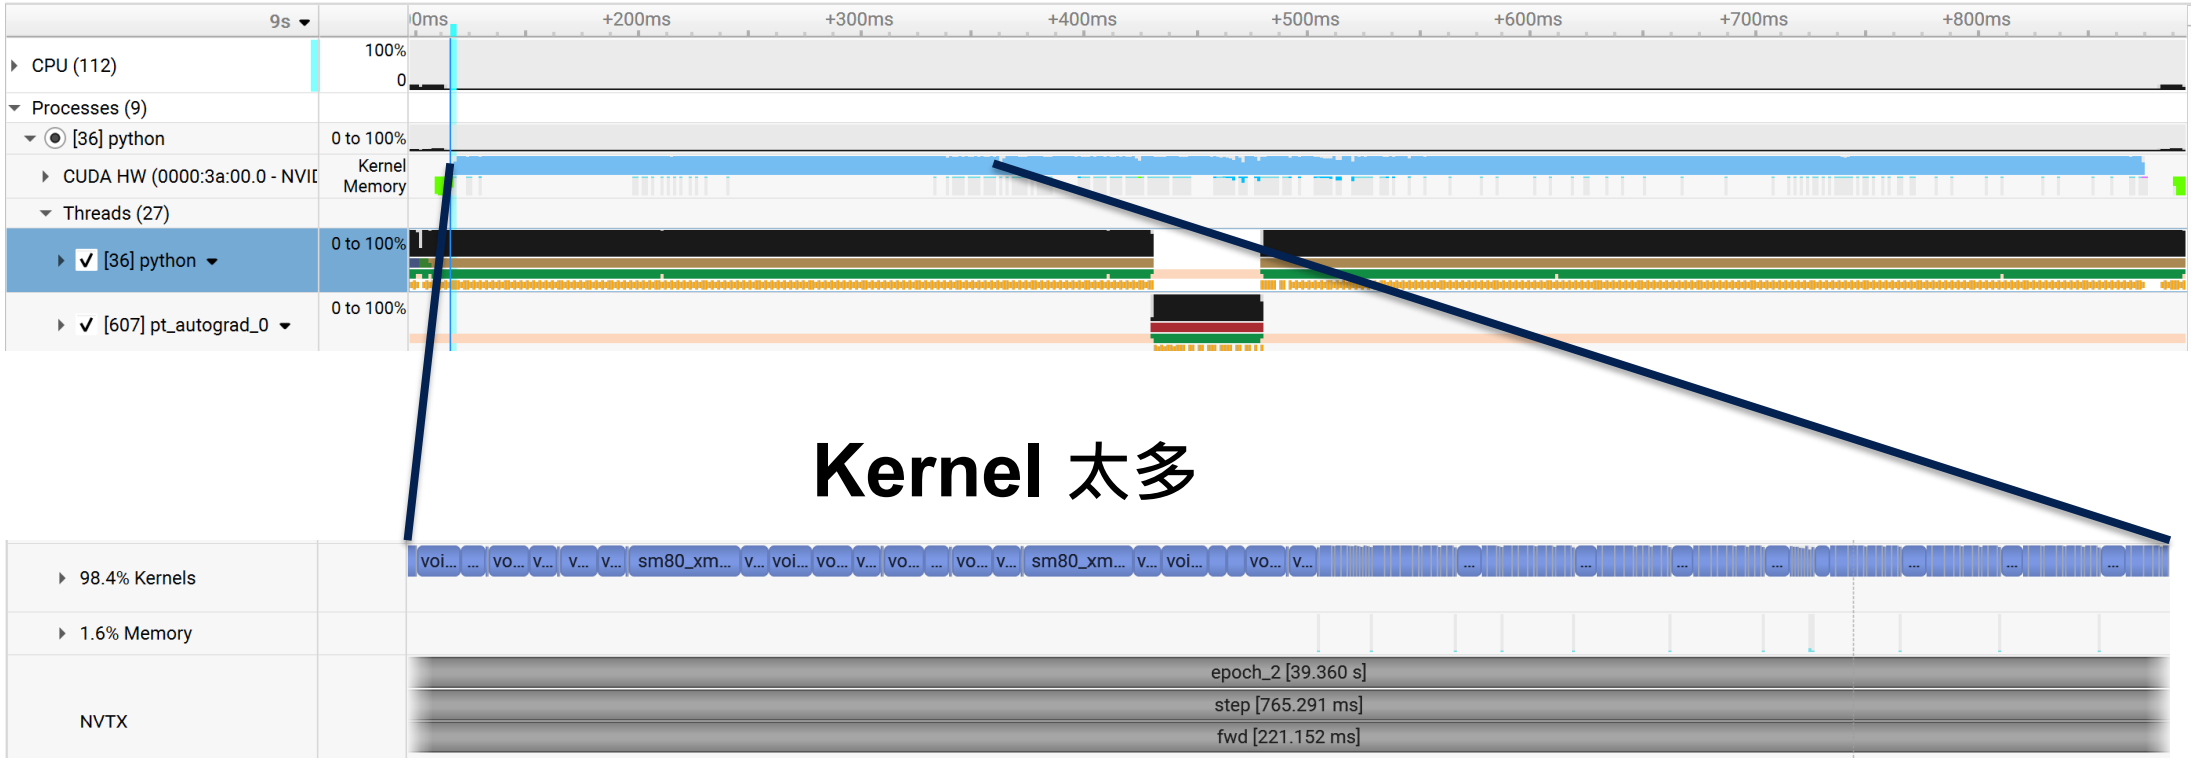
One exception: 70.3%

Histogram matching ran on the CPU while the GPU waited

→ moved to GPU, unused branch removed

→ 70.3% → 75.9%, output bit-identical

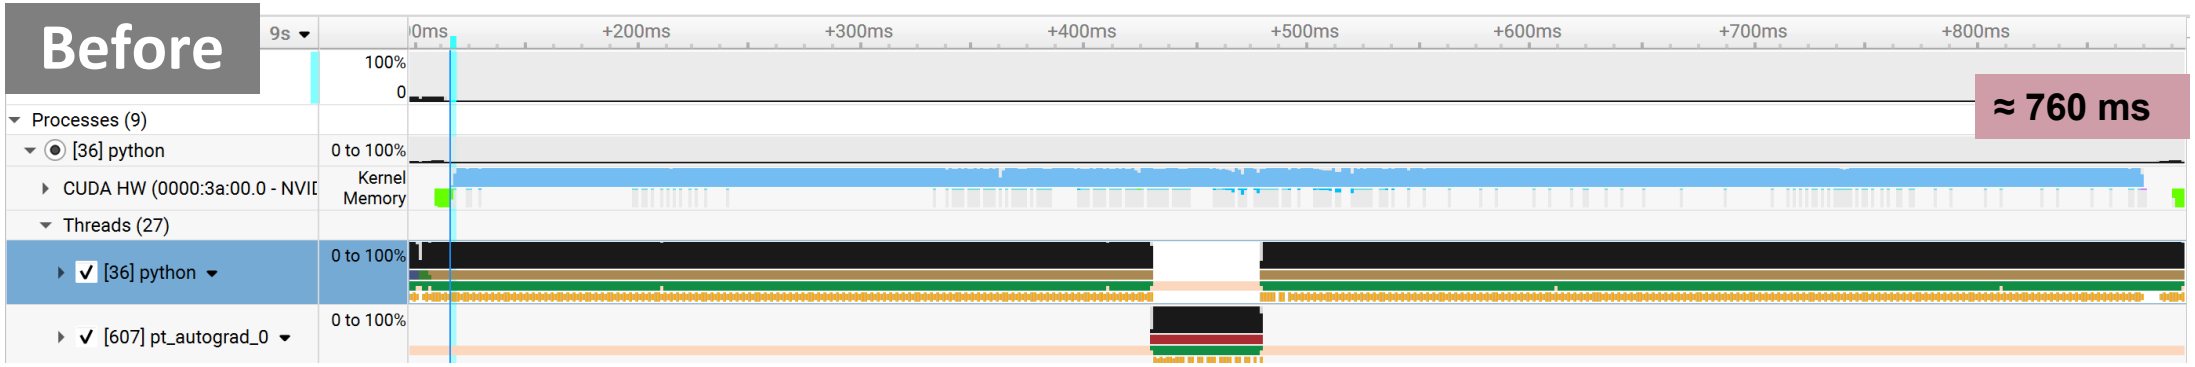
AE Training：48.4 → 38.3 s / epoch（1.27×）



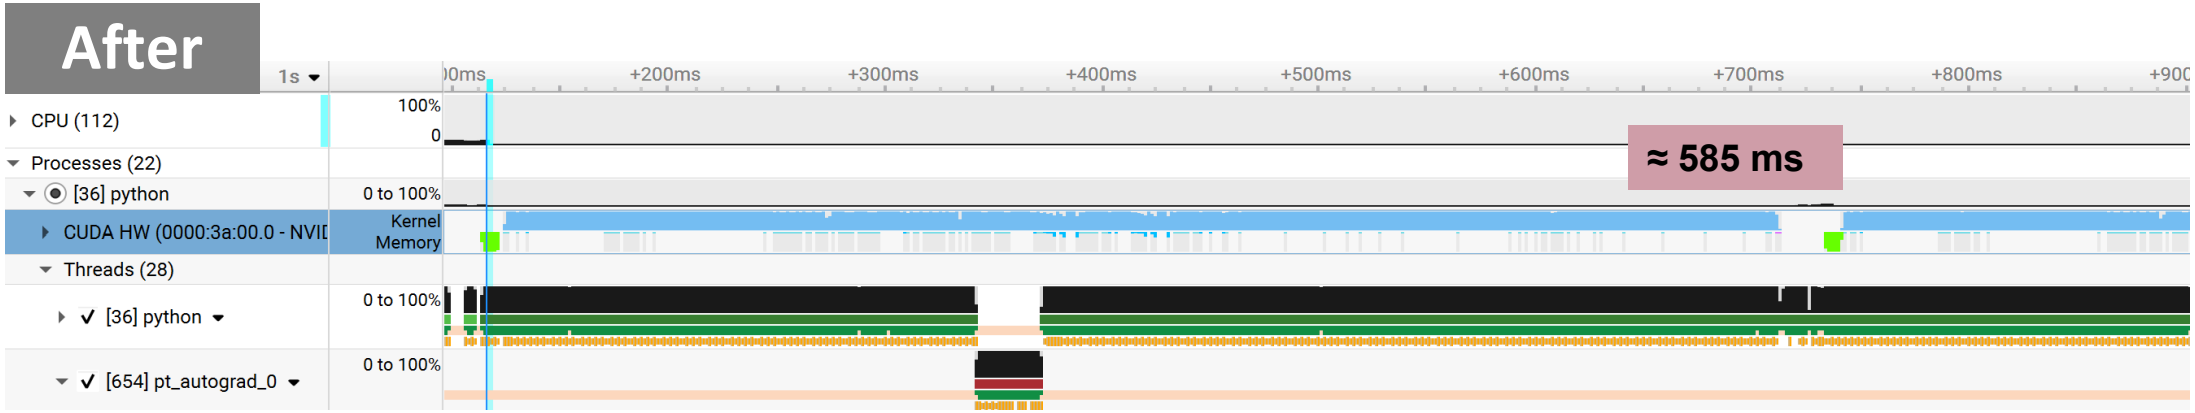
NCHC Nano4 · 1× NVIDIA H200 141 GB

AE Training：48.4 → 38.3 s / epoch（1.27×）

Before



After



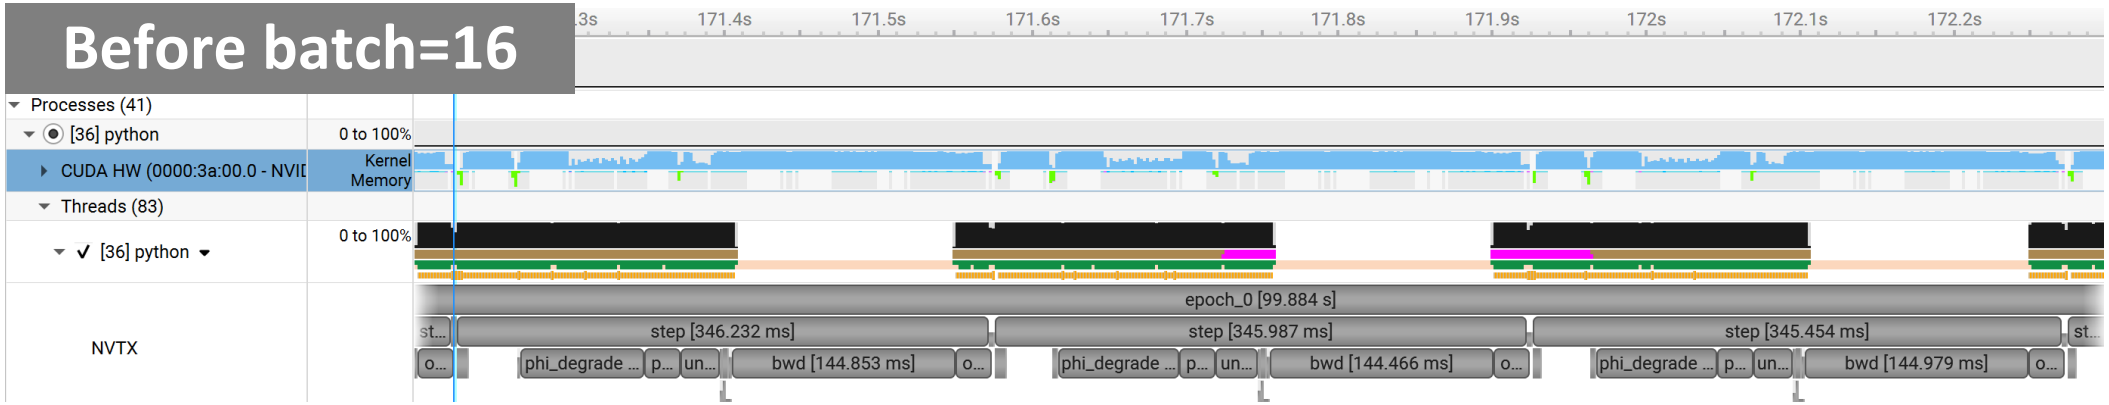
- val loss 差 0.1%（雜訊 0.17%）
- channels_last 0.81×
- DDP 品質下降

NCHC Nano4 · 1× NVIDIA H200 141 GB

OpenACC More Science, Less Programming
OPEN HACKATHONS
NCHC 國家實驗研究院 國家高速網路與計算中心 National Center for High-performance Computing
NVIDIA

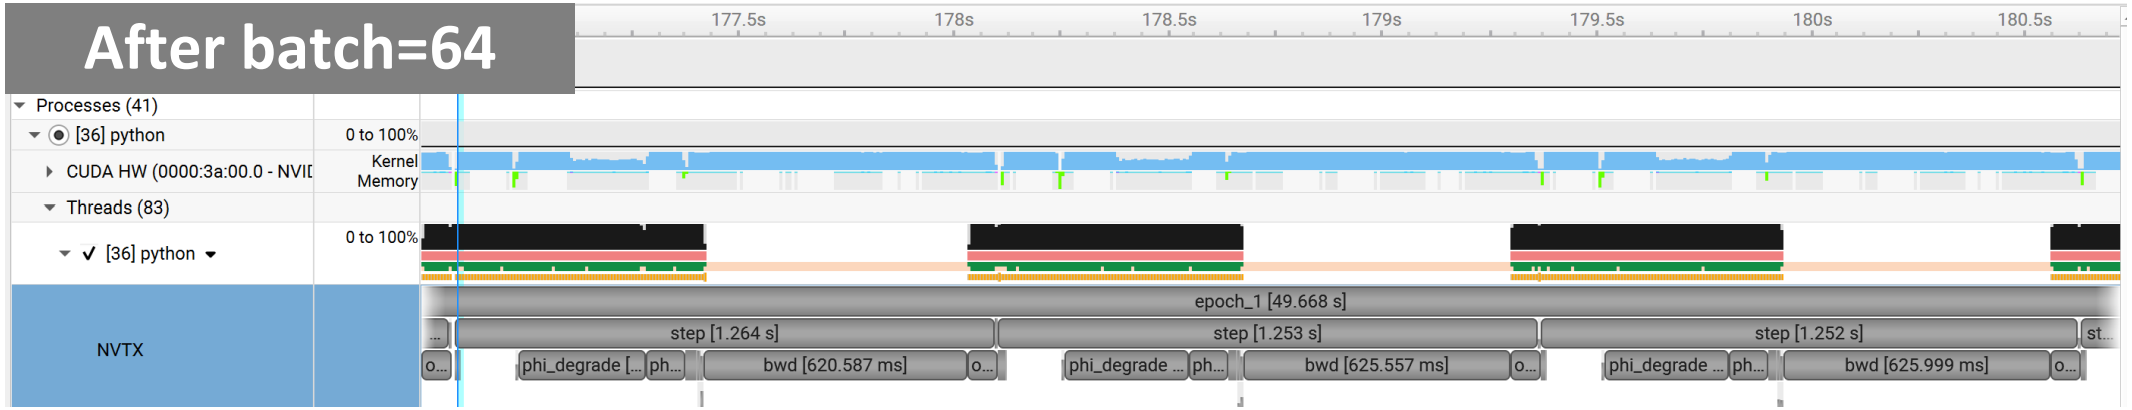
Regression Training：2.56 → 1.82 h（1.41×）

Before batch=16



batch 16 → 64、學習率 ×4、前 5 個 epoch warmup

After batch=64



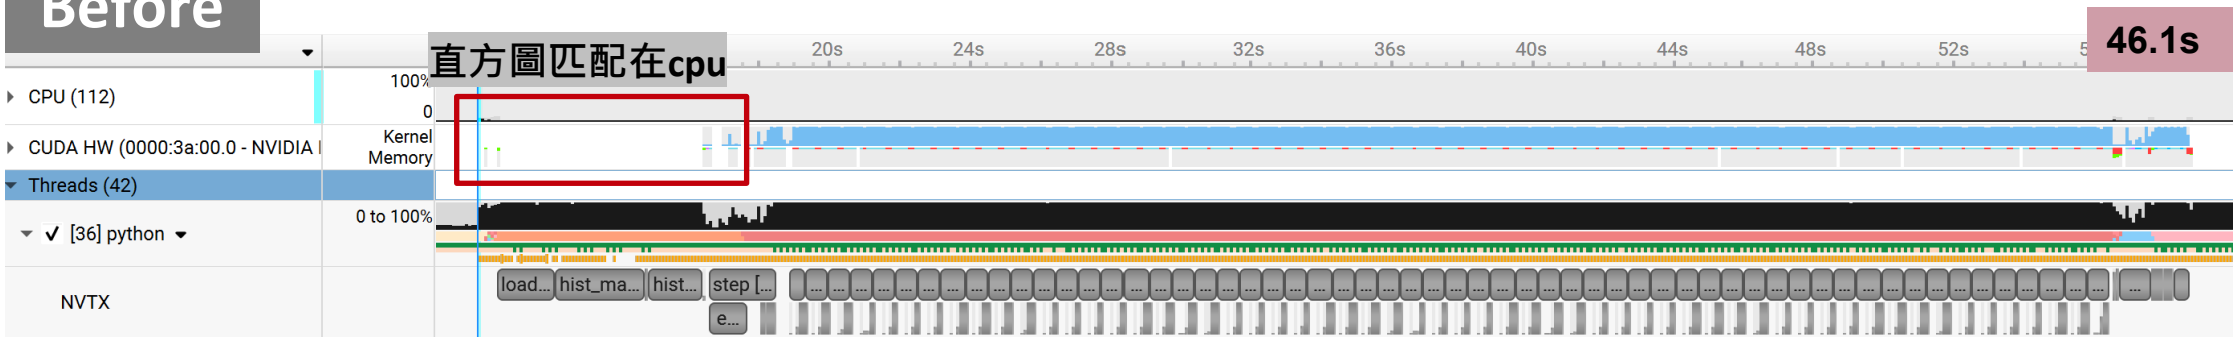
每個 epoch 樣本數減半，總訓練量減少　Chen SSIM −0.0010

NCHC Nano4，1× NVIDIA H200 141 GB

OpenACC More Science, Less Programming　OPEN HACKATHONS　NCHC 國家實驗研究院 國家高速網路與計算中心 National Center for High-performance Computing　NVIDIA

Inference (Deterministic) ：46.1 → 28.5 s（ 1.62× ）

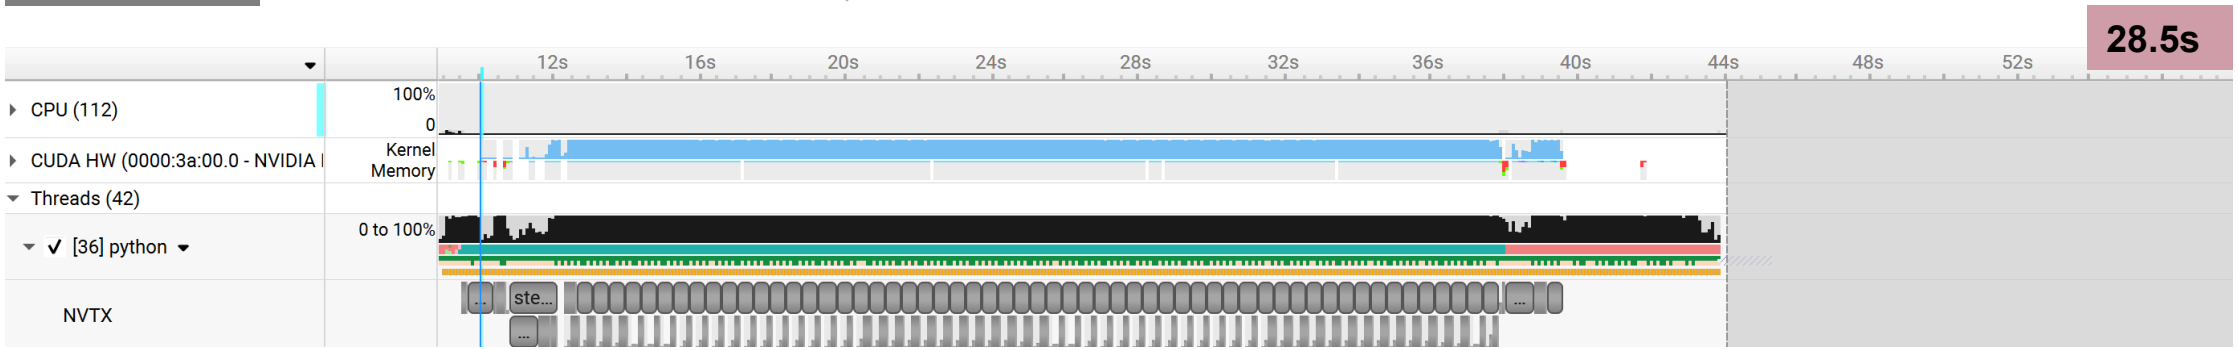
Before



直方圖匹配移到 GPU
跳過用不到的分支
輸出逐位元相同

After

GPU 忙碌 70% → 76%

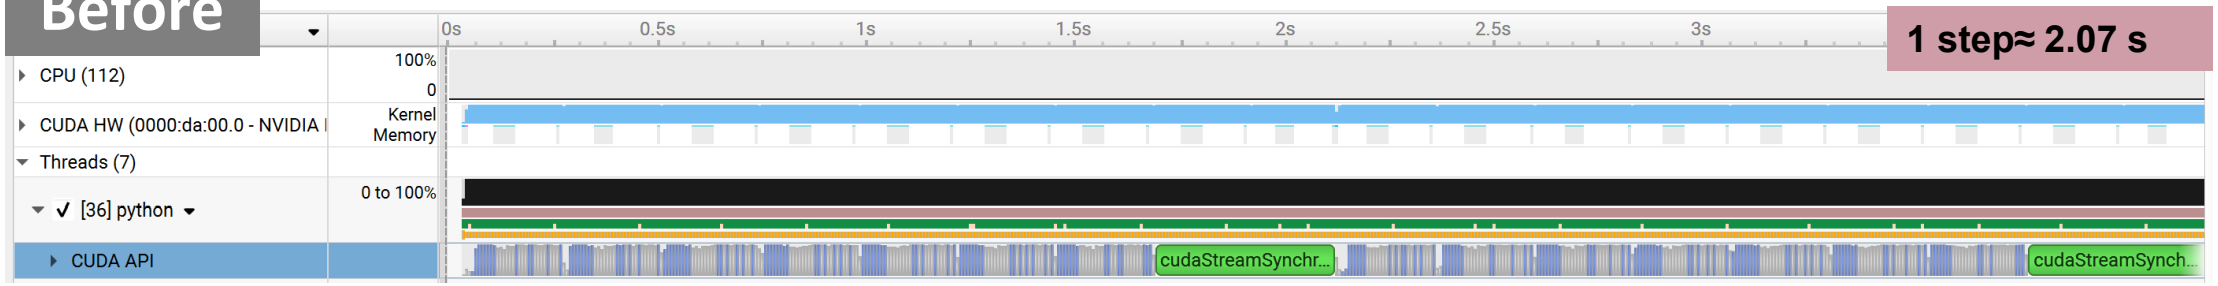


stride 32 快 4.2×，但 PSNR −0.3 dB

NCHC Nano4 · 1× NVIDIA H200 141 GB

Inference (Diffusion) ：40.6 → 22.1 s（ 1.84× ）

Before

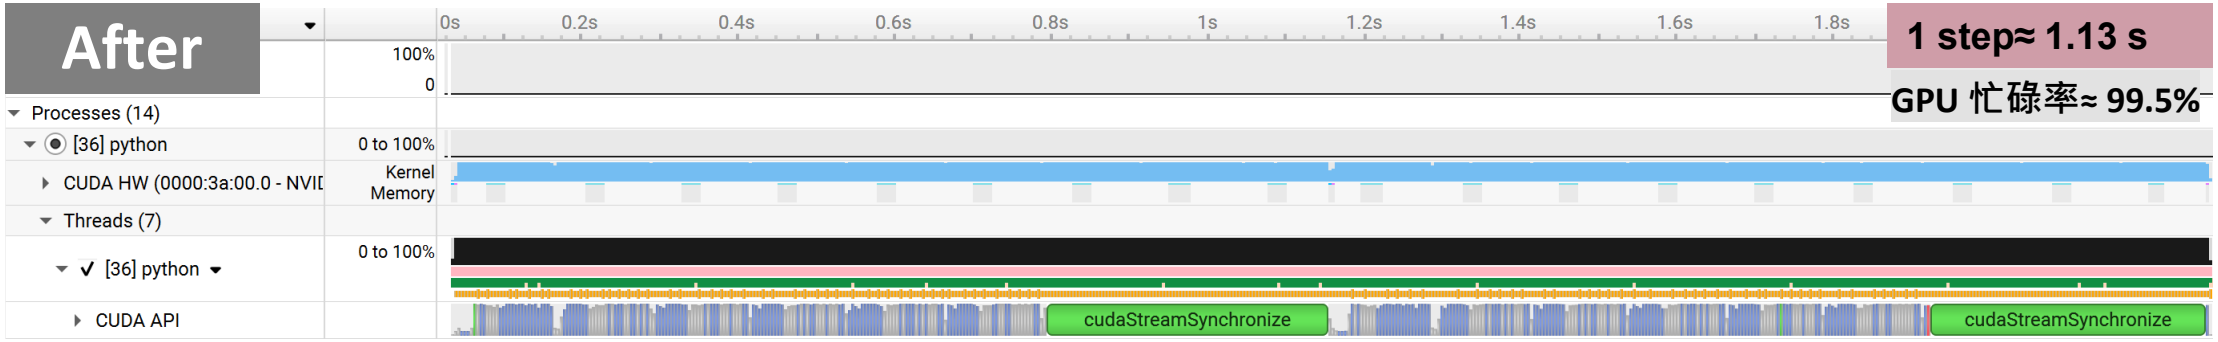


1 step≈ 2.07 s

對 denoiser 開 torch.compile

EVAL SSIM 差 0.00003

After



1 step≈ 1.13 s

GPU 忙碌率≈ 99.5%

NCHC Nano4 · 1× NVIDIA H200 141 GB

OpenACC More Science, Less Programming · OPEN HACKATHONS · NCHC 國家實驗研究院 國家高速網路與計算中心 National Center for High-performance Computing · NVIDIA

Evaluated but Not Adopted

每項皆實測，未通過速度或品質門檻

項目	模組	速度	品質	放棄原因
channels_last_3d	All models	0.81–0.84×	—	實測反而變慢（多一次記憶體格式轉換）
CUDA Graph	Inference	≈1.0×	相同	capture 時鎖定較慢的 fp32 kernel
batch 128	Inference	—	—	上採樣張量超過 INT_MAX（kernel 硬上限）
decoder compile	Regression training	1.23×	PSNR −0.49 dB	端到端品質未過
H2 / H3 訓練 compile	Diffusion training	1.19×	val loss 差 2.5–9.7%	訓練軌跡偏移超過雜訊
stride 16→32	Inference	4.2×	PSNR −0.3 dB	品質未過（另列快速模式）
window batch 96	Diffusion inference	0.99×	逐位元相同	GPU 已 99.5% 忙碌，無空間
Φ 整批計算 / TF32 / decode 合併	All models	1.00×	—	瓶頸不在這裡
8 GPU 平行推論 10 位	Inference	1.26×	相同	每個 process 讀模型與資料的 IO 抵銷

能源效率：CPU vs H200

GPU NODE POWER SAVINGS			
	Baseline	**Comparison**	
	Intel Dual Sapphire Rapids	8x H200 141GB SXM5	**Power Savings**
Compute Power (W)	523,029	10,298	512,731
Networking Power (W)	14,811	880	13,931
Total Power (W)	**537,840**	**11,178**	526,662

Node Power efficiency	**48.1x**

48× 一年省約 460 萬 kWh / 3,271 噸 CO_2

ANNUAL ENERGY SAVINGS PER GPU NODE			
	Intel Dual Sapphire Rapids	8x H200 141GB SXM5	**Power Savings**
Compute Power (kWh/year)	4,581,730	90,210	4,491,520
Networking Power (kWh/year)	129,748	7,709	122,039
Total Power (kWh/year)	**4,711,478**	**97,919**	**4,613,559**

AI Agent: Workflow Throughput

392
Slurm jobs on NCHC Nano4

348
H200 GPU-hours

304
logged experiments

766
git commits
all branches

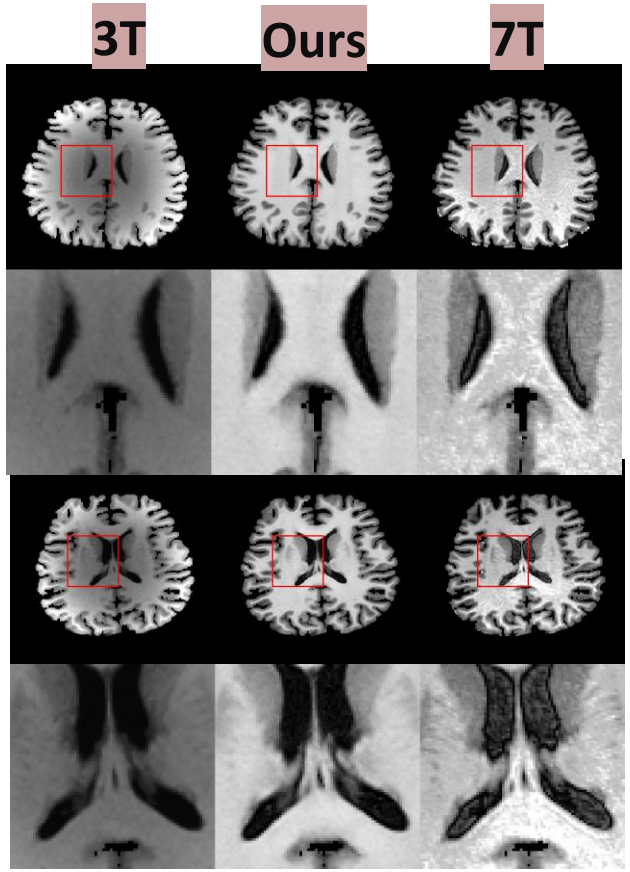
Measured

- ≈ **19** jobs and ≈ **14** logged experiments per day
- **46** written reports, each number tied to a job ID
- **21+** task files handed to agents (plus tasks sent as messages)
- Several agents in parallel, overnight; humans review and decide

CLAUDE + Kimi ≥ 2.7B tokens

Results

SSIM-2D ↑	PSNR ↑	LPIPS ↓
0.875 → 0.905	21.47 → 25.81	0.323 → 0.257



inference

103×

90 min (RTX 3090) → 52s (H200)

training

117×

700 GPU-h (RTX 3090) → 6 GPU-h (H200)

Baseline: MC-IDDPM on RTX 3090 24 GB; Ours: ReDi-7T on 1× H200 141 GB. Speedup includes both method and hardware differences.

OpenACC More Science, Less Programming · OPEN HACKATHONS · NCHC 國家實驗研究院 國家高速網路與計算中心 National Center for High-performance Computing · NVIDIA

Before



我不知道甚麼
是GPU和CPU...

孤立無援
孤軍奮戰
四面楚歌
無依無靠
孤掌難鳴
孑然一身
眾叛親離(?)

Claude agent
燒光我的錢

After(強的離譜ver.)



我有YP！YH！
我有Ken！

我有燒不完的
KIMI醬！

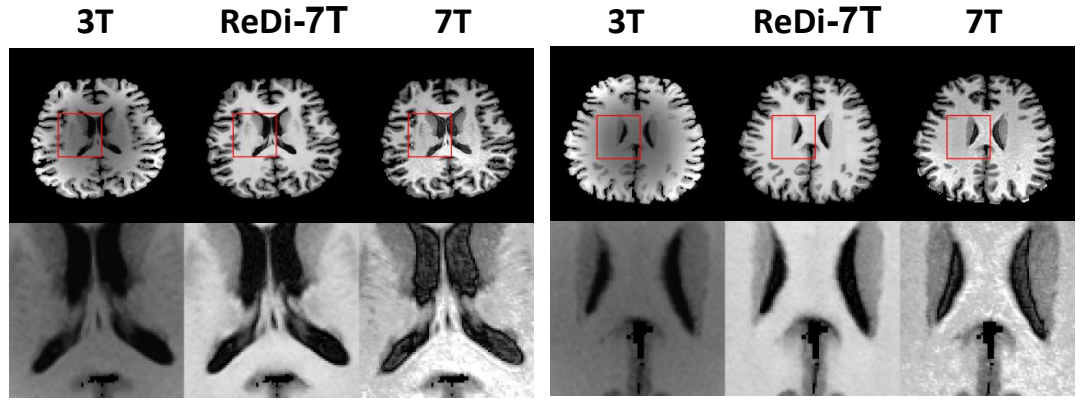
我跑超快！
我是有H200的女
人！

應用背景

7T MRI 具有較高的SNR與空間解析度，能清楚呈現皮質層、細小血管及早期病灶，但受成本與設備限制，臨床普及率極低，多數醫療院所僅配備 3T。

ReDi-7T利用3T影像合成 7T 等級的腦部影像，且無需同一受試者的 3T / 7T 成對資料：利用退化模型 Φ 將 7T 影像轉換像 3T 的影像（pseudo-3T）進行訓練。

方法依空間頻率拆解問題：3T 已含資訊的低、中頻成分，以潛在空間殘差回歸進行確定性還原；超出 3T 解析度的高頻成分，僅以高頻殘差擴散模型補上符合 7T 統計特性的紋理，不改動低頻結構。



Hackathon 目標與做法

目標：不犧牲影像品質，讓 3D 全腦合成的訓練和推論都變快。

環境：PyTorch │ NCHC Nano4 │ NVIDIA H200 141 GB

分析：用 Nsight Systems 看每個模組的時間花費，再用 Nsight Compute 確認主要卷積還有多少優化空間

優化：torch.compile 融合小 kernel（AE 訓練、擴散取樣）；直方圖匹配從 CPU 移到 GPU、移除用不到的分支；回歸 batch 16 → 64

驗證：利用ablation study分別驗證每項加速成果，門檻事先訂好（Chen 評估集 |ΔSSIM| < 0.002、|ΔPSNR| < 0.1 dB），沒通過的照實列為 negative results

技術成果與影響

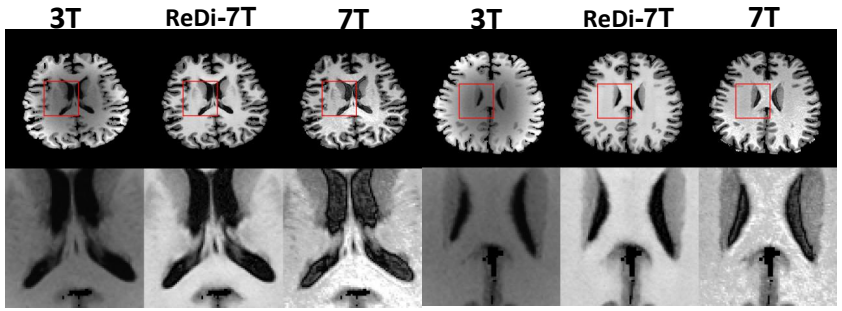
Inference：一位受試者 90min → 52 s（約 103×）
Training：700 GPU-h → 約 6 GPU-h（約 117×）

前：MC-IDDPM（實驗室既有 3D 擴散模型），NVIDIA RTX 3090 24 GB
後：ReDi-7T，NVIDIA H200 141 GB × 1
倍數含方法與硬體差異

影像品質（Chen 評估集，輸入 3T → ReDi-7T）：
SSI0.875 → 0.905，PSNR 21.47 → 25.81 ，LPIPS 0.323 → 0.257

OpenACC More Science, Less Programming
OPEN HACKATHONS
NCHC 國家實驗研究院 國家高速網路與計算中心 National Center for High-performance Computing
NVIDIA

ReDi-7T：3T → 7T 腦部 MRI 合成



為甚麼SSIM不能上升團隊成員來自長庚大學「趙一平老師實驗室」，將 3T→7T 全腦影像合成推論加速 103 倍！

— NVIDIA Mentors: Yang-Hsien Lin, Ken Liao

7T 磁振造影比常見的 3T 解析度更高、訊號更清楚，能看清皮質分層、細小血管與早期病灶，對多發性硬化、癲癇等疾病的診斷更有幫助。但 7T 設備昂貴，全世界僅有146台，全台灣還未有用在人體上的7T MRI 磁振造影。

若能以 3T 影像合成出 7T 等級的影像，就能讓更多病人受益。困難在於幾乎沒有同一個人同時掃 3T 和 7T 的資料，而且醫學影像對於幻覺的規範更嚴謹，憑空多出的結構可能被誤認為病灶。
我們提出 **ReDi-7T**，名字來自它的兩個核心：**Re**gression（回歸）與 **Di**ffusion（擴散）。我們先用「退化模型」把 7T 變成擬 3T 影像；將3T 本來就有的資訊交給回歸模型確定性地還原，超出 3T 解析度的部分才交給擴散模型，只補上符合 7T 統計特性的紋理。

我們在 NVIDIA H200 上用 Nsight Systems 找出每個環節的瓶頸，逐項優化，每一項都先確認影像品質沒有下降才採用。與實驗室既有的 3D 擴散模型（RTX 3090）相比，ReDi-7T 在 H200 上合成一顆腦從 90 分鐘縮短到 52 秒，訓練從 700 GPU 小時降到約 6 小時。不到一分鐘就能完成一顆腦，代表這個方法有機會在掃描後立即提供 7T 等級的參考影像；訓練變快，也讓我們一天內能進行多種消融實驗，把力氣放在讓合成影像在不同醫院、不同機器上都穩定可靠。

Table 1: Elapsed time of ReDi-7T (1× NVIDIA H200 141 GB, NCHC Nano4).

Stage	Unit	Baseline	Optimized
AE training	s / epoch	48.4	38.3 (1.27×)
Regression training	h	2.56	1.82 (1.41×)
Inference: deterministic	s / subject	46.1	28.5 (1.62×)
Inference: H3 diffusion	s / subject	40.6	22.1 (1.84×)
Inference: total	s / subject	87	52 (**1.67×**)
vs MC-IDDPM: inference	s / subject	5400	52 (**103×**)
vs MC-IDDPM: training	GPU-h	700	≈ 6 (**117×**)

Inference: deterministic 含 AE 編碼 / 解碼、guided filter、直方圖匹配；推論為一位受試者、取樣 1 次。MC-IDDPM 為實驗室既有 3D 擴散模型（RTX 3090 24 GB），倍數含方法與硬體差異。


Thank You
OpenACC
More Science, Less Programming